Автоматизация признаков для рекомендательной системы

Ислам / Islam-Y · 12 октября 2026
github.com/Islam-Y/RecSys

Итоговый отчёт по первому заданию T-Lab 2026. Хронология запусков, дополнительные таблицы и команды приведены в журнале исследования и README.

Краткий итог

Реализованы временной pipeline на DuckDB и CatBoost, генератор 70 формул и автоматический отбор восьми числовых признаков вместо ручных двенадцати. На расширенной проверке из 7 025 запросов автоматический набор уступил ручному по NDCG@3: 0.4343 против 0.4444. Его расчёт оказался на 14.2% медленнее, а пиковая память - на 21.9% выше.

Положительный эффект получен для размера числовой матрицы (-33.3%) и сохранённой модели (-93.8%), но с потерей качества. Основной вывод: ограничение числа признаков не заменяет ограничение вычислительной стоимости. Проверенный селектор автоматизирует поиск внутри заданной грамматики, однако не обеспечил заранее установленный компромисс качества и ресурсов.

1. Задача и выбранный подход

Задание предлагает построить базовый pipeline с градиентным бустингом и временными признаками, а затем либо проверить идею автоматизации генерации признаков, либо показать метод, превосходящий хорошо настроенный бустинг.

Мы выбрали первый путь: автоматически строить и отбирать признаки из пространства заранее заданных формул, затем сравнивать результат с ручным набором при общем лимите в 12 числовых признаков. Это ограниченная автоматизация, а не генерация произвольного SQL или самостоятельное открытие новых типов признаков.

Соответствие исходному условию:

Требование	Что сделано
Базовый бустинг и инженерные признаки	CatBoost; агрегаты пользователя, трека и пары
Признаки только до момента T	Строгое условие timestamp < T во всех агрегатах
Идея автоматизации и эксперименты	Генератор формул, отбор по нескольким срезам, отдельная проверка качества и затрат
Независимость от ручного выбора	Частично: формулы выбираются автоматически, грамматика и окна заданы человеком
Превосходство над настроенным бустингом	Альтернативный путь не заявлен; локальная настройка выполнена как контроль

Упоминания 1 млн, 1 млрд и 100 млрд взаимодействий находятся в абзаце задания о подаче всей истории в трансформер. Для pipeline с бустингом условие не задаёт обязательный production throughput или SLA. Наши пакетные измерения на 47,8 млн строк не являются нагрузочным тестом на миллиарды событий.

2. Данные и протокол оценки

Использована официальная Yambda-50M: 47 790 449 событий, 10 000 пользователей и 934 057 треков в файле **flat/50m/multi_event.parquet**. Лицензия датасета - Apache 2.0. Сырые данные и локальные модели в репозиторий не добавлены.

Целевая реакция. Позитив - событие **listen** с **played_ratio_pct > 50** (Listen+). Датасет не содержит журналов показов без взаимодействия. Поэтому негативы - сэмплированные неизвестные объекты, а не подтверждённые дизлайки или показы без клика. Пользователь мог бы послушать такой трек позднее; метрики не оценивают CTR или онлайн-эффект.

Набор кандидатов. Для каждого момента рекомендации формировались в среднем около 50 негативов и одного позитива. В смешанном варианте негативы предлагались из раннего пула популярных треков и равномерно из каталога. Пул из 50 000 треков строился на раннем warm-up-участке, который не входил в запросы оценки. Уже встречавшиеся пользователю объекты и целевой позитив исключались из негативов.

Время и разбиение. Timestamp Yambda выражен в секундах с шагом 5 секунд. В ранней версии timestamp ошибочно трактовался как номер пятисекундного интервала; время растягивалось в пять раз. Ошибка исправлена. Теперь при переносе в DuckDB секунды преобразуются в микросекунды множителем 1 000 000. Суточная длительность benchmark задана как 86 400 секунд в официальных константах. Календарная дата в эксперименте условная.

Препроцессор выбрал 10 341 временную метку: первые 2 069 использовались для warm-up. Основной candidate-набор содержит 8 061 запрос, 9 210 позитивов и 403 050 негативов. После warm-up он разделён по времени на train, validation и test в пропорции 70/15/15. В test - 1 208 запросов. Это разбиение нашего эксперимента, не официальный split Yambda. Для поиска окон и автоматического отбора использовались отдельные временные срезы; их состав указан в соответствующих разделах.

Здесь «запрос» - группа кандидатов для одного пользователя в момент T, а не онлайн-запрос к сервису.

Все признаки для момента T рассчитывались только по событиям с timestamp < T. Основные метрики - NDCG@3 и Recall@3, усреднённые по запросам. NDCG@3 учитывает релевантность и порядок первых трёх объектов; Recall@3 - долю позитивов в этой тройке без учёта порядка между позициями.

3. Базовый ranking pipeline

Признаки пользователя, трека и пары «пользователь - трек» пакетно рассчитываются в DuckDB. CatBoostClassifier обучается на позитивных событиях и сэмплированных неизвестных объектах; кандидаты одного запроса сортируются по оценке модели. Baseline популярности сортирует тот же набор кандидатов по числу Listen+ за предыдущие 30 дней.

Негативы в candidate set	Метод	NDCG@3	Recall@3
Равномерные	CatBoost	0.8450	0.8811
Равномерные	Популярность за 30 дней	0.6973	0.7822
Смешанные: популярные и равномерные	CatBoost	0.7358	0.7622
Смешанные: популярные и равномерные	Популярность за 30 дней	0.3992	0.4673

CatBoost превосходит baseline популярности в обоих протоколах. Результаты на равномерном и смешанном наборах нельзя трактовать как изолированный эффект сложности негативов: под каждый

протокол модель обучалась заново. В любом случае оценка относится только к сэмплированным кандидатам, а не к фактическим показам сервиса.

4. Временные окна и бюджет признаков

В первоначальной validation-абляции семь окон 1/3/7/14/30/60/90 дней дали NDCG@3 = 0.8074 и Recall@3 = 0.8237. Добавление давности последнего события повысило их до 0.8109 и 0.8254; тренд дал 0.8085 и 0.8216, а оба признака вместе - 0.8078 и 0.8227. В следующем поиске сравнивались наборы при разных лимитах окон; поиск был жадным, а не полным перебором комбинаций.

Поиск окон при бюджете признаков

В этой серии наибольший прирост дало добавление окна 90 дней к исходным 1/7/30.

Окна, дни	Признаков, включая 2 ID	Поздний NDCG@3	Поздний Recall@3	Ранний NDCG@3	Ранний Recall@3	Расчёт признаков, с
1/7/30	11	0.7519	0.7738	0.7518	0.7742	1.093
1/7/30/90	14	0.8094	0.8229	**0.8205**	**0.8321**	1.495
1/7/14/30/90	17	0.8111	0.8267	0.8201	0.8310	1.618
1/7/14/30/60/90	20	**0.8114**	**0.8270**	0.8197	0.8318	1.836
1/3/7/14/30/60/90	23	0.8074	0.8237	0.8180	0.8302	1.973

Поздний срез: обучение до 70-го процентиля времени и validation от 70-го до 85-го (1 208 запросов). Ранний срез: обучение до 50-го и validation от 50-го до 70-го (1 612 запросов). Все значения в таблице - validation, не финальная test-оценка.

Окно 90 дней дало основную прибавку: на позднем срезе NDCG@3 выросла с 0.7519 до 0.8094, а расчёт признаков занял на 0.402 секунды больше. Пятое и шестое окна изменили результат позднего среза незначительно; на раннем срезе лучший результат показали четыре окна. Семь окон уступили более компактным вариантам на обоих срезах. Следовательно, большее число окон само по себе не гарантирует лучшее качество.

Тренд активности и давность последнего события не дали устойчивого улучшения: давность помогла в первой серии с семью окнами, но не улучшила компактные наборы; тренд не показал стабильной прибавки.

Проверка горизонтов 120 и 180 дней

Горизонт последнего окна	Поздний NDCG@3 / Recall@3	Ранний NDCG@3 / Recall@3	Расчёт признаков, с
90 дней	0.8094 / 0.8229	0.8205 / 0.8321	1.379
120 дней	0.8244 / 0.8367	0.8327 / 0.8443	1.475
180 дней	0.8399 / 0.8505	0.8443 / 0.8548	1.611

В этом протоколе правило «история старше 90 дней бесполезна» не подтвердилось. Validation начинается после 200-го дня истории, поэтому окна 120 и 180 дней доступны целиком; в ранней части train история 180 дней ещё неполная. Преимущество 180 дней частично объясняется и устройством выборки: у 6 756 из 9 210 позитивов была история Listen+ той же пары в предыдущие 180 дней; негативы

по правилу сэмплирования всегда были неизвестными пользователю. На диагностической подвыборке без повторного Listen+ пары за 180 дней NDCG@3 при переходе с 90 на 180 дней выросла на 0.0106 на позднем и на 0.0093 на раннем срезе; Recall@3 вырос на позднем, но немного снизился на раннем. Это меньшая выборка с отдельными временными границами, поэтому результат не доказывает, что 180-дневную историю стоит хранить в production.

Время расчёта признаков измерено локально в пакетном запуске. Задержка онлайн-чтения, стоимость хранения и пропускная способность не измерялись.

5. Автоматический поиск признаков

Пространство признаков задано шаблоном:

сущность × тип события × окно × агрегат

Генератор строит 70 формул для пользователя и трека, четырёх типов события (Listen+, короткое прослушивание, like и dislike), окон 1/7/30/90/180 дней и агрегатов: число событий, число разных контрагентов и средняя доля воспроизведения. Каждый признак строится только из событий до момента T. Признаки пары «пользователь - трек» в поиск не включены: автоматический отбор оценивался на запросах без прежних взаимодействий с позитивными треками, поэтому такие признаки были бы нулевыми по построению выборки. Это поиск внутри вручную заданной грамматики; произвольные связи, таблицы и преобразования система не открывает сама.

Ручной контроль состоял из счётчиков Listen+ пользователя и трека за 1/7/30/90 дней, числа разных прослушанных треков пользователя и разных слушателей трека за 30/90 дней - всего 12 числовых признаков - и двух идентификаторов. Автоматический отбор ограничивался 12 числовыми признаками. Для устойчивого порядка формул важности CatBoost переводились в нормированные ранги на каждом из четырёх срезов (seed 42/43 и временные разбиения 35/55/70 и 50/70/85); итоговый порядок определялся средним рангом. Бюджеты 4, 8 и 12 сравнивались по критерию «средний NDCG@3 - 0.5 × стандартное отклонение»; выбран набор из восьми признаков.

На первых проверках результат менялся вместе с выборкой: на одном позднем срезе автоматический набор опередил ручной, на другом уступил ему. Поэтому итоговое сравнение сделано на отдельном query seed 44, не участвовавшем в выборе формул в этой процедуре. Из 1 862 запросов после фильтра повторных позитивов в audit-срез 70-85-го процентиля вошли 279. Query ID audit не пересекаются с discovery, но диапазон 70-85% уже использовался как validation в ранних экспериментах проекта; это не полностью нетронутая проектная test-выборка.

Устойчивый отбор и audit seed 44

Метод	NDCG@3	Recall@3
Популярность за 30 дней	0.3294	0.4140
Ручной CatBoost, 12 признаков	**0.3927**	**0.4713**
Автоматический отбор, 8 признаков	0.3881	0.4624

Разность NDCG@3 «автоматический минус ручной» - -0.0046; 95% bootstrap-интервал по запросам [-0.0351; +0.0275]. Он включает ноль. Результат совместим и с небольшим проигрышем, и с небольшим выигрышем; доказательств превосходства автоматического отбора нет. Интервал рассчитан повторной выборкой запросов, поэтому он не учитывает возможную зависимость запросов одного пользователя.

Чувствительность к сэмплированию

На одной когорте из 285 запросов при смене seed сэмплера негативов (он менял обучающие, selection- и audit-негативы) NDCG@3 ручного CatBoost менялась от 0.3645 до 0.4023, автоматического набора - от 0.3753 до 0.3880. Это подчёркивает, что результаты на сэмплированных неизвестных зависят от состава выборки.

Полный запуск устойчивого отбора занял около 149 секунд на этой машине. Это время пакетного offline-эксперимента, а не задержка онлайн-выдачи.

6. Проверки модели и настройки CatBoost

Сравнение CatBoostClassifier и CatBoostRanker

Сравнили CatBoostClassifier с CatBoostRanker на тех же наборах запросов, candidate-пулах и двух вариантах признаков. При общей NDCG-метрике выбора числа итераций точечная NDCG@3 у Ranker была выше во всех 18 сравнениях. Однако 95% парные интервалы исключали ноль только в 2 из 18; поправка на множественные сравнения не применялась. Это основание для дальнейшей проверки ranking objective, но не доказательство устойчивого превосходства Ranker.

Подбор параметров CatBoost

Проверили восемь заранее заданных конфигураций на discovery-когортах q45/q46. Выбранная конфигурация depth=8, learning_rate=0.10, l2_leaf_reg=3 сравнивалась с фиксированной depth=8, learning_rate=0.05, l2_leaf_reg=3 на q47 при одинаковом правиле остановки по NDCG@3.

Конфигурация на q47	NDCG@3	Recall@3
Фиксированная	0.47836	0.55961
Выбранная на discovery	0.47853	0.56237

Парная разность NDCG@3 - +0.00017; пользовательский 95% bootstrap-интервал [-0.00604; +0.00644]. Выигрыш не подтверждён. Это короткий поиск по сетке, а q47 использовалась и в более ранних экспериментах проекта, поэтому её нельзя считать полностью нетронутым финальным holdout.

Мы не нашли публичного CatBoost-результата на Yambda с теми же candidate set, разбиением и метриками. Benchmark CatBoost использует другой набор - Yandex LETOR - и NDCG@10, поэтому его score нельзя напрямую сравнивать с нашим NDCG@3. Локальный эксперимент не доказывает, что найден или превзойдён глобально хорошо настроенный CatBoost.

7. Проверка стоимости на новой выборке

После первоначальных сравнений поставили отдельный вопрос: экономит ли выбранный набор из восьми признаков ресурсы при приемлемой потере качества? Протокол зафиксирован до подготовки новых данных. Совместный критерий: минимум 20% ускорения, рост peak RSS не более 5% и подтверждённая пользовательским 95% bootstrap-интервалом потеря NDCG не более 2% относительно ручного контроля. Допуск 2% - исследовательский порог, не бизнес-требование.

Query seed 48 и hash modulo 100 дали 46 839 запросов и 2 390 544 candidate-строки. Query ID всех прежних candidate-файлов исключены; пересечение равно нулю. У всех позитивов и негативов проверено отсутствие прежних взаимодействий пары. Каталог и популярный пул заморожены на границах q45; 50 смешанных негативов и ранее выбранные формулы сохранены. Разбиение по времени уникальных запросов: train 50%, selection следующие 35%, audit последние 15%. В audit вошли 7 025

запросов от 3 365 пользователей, 358 550 candidate-строк. Это новые запросы на том же Yambda, не внешний датасет; пользователи и история могут совпадать с предыдущими опытами.

Обе модели - CatBoostClassifier depth 8, learning rate 0.05, L2 3, seed 42. Число итераций выбиралось по Logloss на selection, как в исходном отборе, затем модель переобучалась на train+selection без early stopping на audit. Ручной вариант выбрал 292 итерации, автоматический - 85. Признаки и параметры на audit не менялись.

Показатель	Ручные 12 признаков	Автоматические 8
NDCG@3	**0.44435**	0.43434
Recall@3	0.51775	0.51217
Медиана расчёта и выгрузки audit-матрицы, с	**2.997**	3.423
Медиана пикового RSS процесса, MiB	**2 261**	2 757
Числовая audit-матрица, MiB	32.83	**21.88**
Сохранённая модель, MiB	429.11	**26.58**

Парная разница NDCG@3 «авто минус ручной» - -0.01001; 95% пользовательский bootstrap-интервал [-0.01469; -0.00535], 5 000 повторов. Точечная потеря - 2.25% относительно контроля. Для критерия допустимой потери интервал NDCG_auto - 0.98 × NDCG_manual равен [-0.00571; +0.00349]: потеря не более 2% не подтверждена. Обе хронологические половины audit также дали отрицательные точечные разницы; они приведены как диагностика, без выбора лучшей половины.

Стоимость измерена после одного прогрева в пяти последовательных отдельных процессах на вариант, с чередованием порядка. У обеих конфигураций четыре потока DuckDB и memory_limit 6 GB. Измерено построение и выгрузка полной audit-матрицы из истории; запуск Python и подготовка examples в длительность не входят. Кэш ОС не очищался. Пиковый RSS относится ко всему процессу, а не только к числовой матрице.

Совместный критерий не выполнен по всем трём условиям. Восемь признаков оказались дороже двенадцати: автоматический набор включает 180-дневные агрегаты и средние доли воспроизведения, ручной ограничен 90 днями. Измерение не изолирует вклад каждой формулы, но показывает, что число признаков - недостаточная мера затрат. При текущем расчёте прежний поиск длительностью 148.755 с не окупается ускорением последующих обновлений.

Отдельный положительный результат - компактность. Числовая матрица уменьшилась на 33.3%, файл модели - на 93.8%. Размер модели - вторичное наблюдение при выбранном правиле остановки; у моделей разное число деревьев, поэтому эффект нельзя приписать только числу признаков. Задержка инференса и онлайн-хранение не измерялись; меньший файл не подтверждает сохранение качества.

Технические исправления подготовки матрицы и экспорта отражены в журнале; сохранённые модели не переобучались после проверки. Агрегированный результат и все измеряемые повторы сохранены в проекте.

8. Выводы и ограничения

1. Реализован бустинговый ranking pipeline с point-in-time признаками и воспроизводимыми экспериментами на Yambda-50M.
2. Реализован ограниченный генератор и селектор признаков. Он автоматизирует перебор внутри заданной грамматики, но на расширенной проверке уступил ручному набору по NDCG и затратам расчёта.
3. Более длинная история улучшила offline-метрики на части срезов, но эффект зависит от состава кандидатов и особенно от повторных позитивов. По этим данным нельзя назначить production-горизонт хранения.
4. Проверены CatBoostRanker и короткая настройка параметров. Оба дали положительные точечные сигналы в части сравнений, но данных недостаточно, чтобы утверждать надёжное превосходство.
5. Автоматический набор дал меньшую числовую матрицу и существенно меньший файл модели. Это измеренные преимущества компактности с потерей качества; заданный компромисс ресурсов и NDCG не достигнут.
6. Поскольку нет журналов показов, метрики не измеряют CTR, интерес к непоказанным объектам или онлайн-лифт. Пакетный расчёт на 47,8 млн событий не подтверждает масштабирование до миллиарда и более.

Итог задания - реализованный и экспериментально проверенный подход к автоматизации признаков с установленными ограничениями. Следующая содержательная гипотеза - отбирать формулы с учётом измеренной стоимости расчёта и допустимой потери качества, затем проверять новый селектор на новых данных. Для оценки CTR и онлайн-эффекта отдельно нужны реальные показы и контролируемый онлайн-эксперимент.

9. Воспроизведение и источники

Команды подготовки данных и запуска экспериментов - в README. Полная последовательность гипотез и запусков - в журнале исследования.

- Условие первого задания
- Страница отбора T-Lab 2026. RecSys
- Yambda: карточка, схема и лицензия датасета
- Yambda-5B: статья и описание benchmark split
- Yambda: константы времени
- Yambda: реализация временного разбиения
- CatBoost: ranking benchmark
- CatBoostRanker: документация